

In [1]:

```
import numpy as np
import matplotlib.pyplot as plt
from sklearn.model_selection import train_test_split
```

In [2]:

```
perch_length = np.array([8.4, 13.7, 15.0, 16.2, 17.4, 18.0, 18.7, 19.0, 19.6, 20.0,
    21.0, 21.0, 21.3, 22.0, 22.0, 22.0, 22.0, 22.0, 22.5, 22.5, 22.7,
    23.0, 23.5, 24.0, 24.0, 24.6, 25.0, 25.6, 26.5, 27.3, 27.5, 27.5,
    27.5, 28.0, 28.7, 30.0, 32.8, 34.5, 35.0, 36.5, 36.0, 37.0, 37.0,
    39.0, 39.0, 39.0, 40.0, 40.0, 40.0, 40.0, 42.0, 43.0, 43.0, 43.5,
    44.0])
perch_weight = np.array([5.9, 32.0, 40.0, 51.5, 70.0, 100.0, 78.0, 80.0, 85.0, 85.0,
    115.0, 125.0, 130.0, 120.0, 120.0, 130.0, 135.0, 110.0, 130.0,
    150.0, 145.0, 150.0, 170.0, 225.0, 145.0, 188.0, 180.0, 197.0,
    218.0, 300.0, 260.0, 265.0, 250.0, 250.0, 300.0, 320.0, 514.0,
    556.0, 840.0, 685.0, 700.0, 700.0, 690.0, 900.0, 650.0, 820.0,
    850.0, 900.0, 1015.0, 820.0, 1100.0, 1000.0, 1100.0, 1000.0,
    1000.0])
```

In [3]:

```
print(type(perch_length))
print(type(perch_weight))
```

```
<class 'numpy.ndarray'>
<class 'numpy.ndarray'>
```

In [4]:


```
print(len(perch_length))
print(len(perch_weight))
```

56

56

In [5]:

```
# 농어의 길이가 늘어나면, 무게도 늘어난다
# => 양의 상관관계(시험!)
# 상관계수 값:-1~1
# 1에 가까울수록 양의 상관관계
# -1에 가까울수록 음의 상관관계
# 0에 가까울수록 관계 없음(보통 상관관계가 +-0.4이상이면 사용 가능)
plt.scatter(perch_length, perch_weight)
plt.xlabel('perch_length')
plt.ylabel('perch_weight')
plt.show()
```



In [6]:

```
train_input, test_input, train_target, test_target = train_test_split(perch_length,
```

In [7]:

```
print(train_input.shape, test_input.shape)
```

```
(42,) (14,)
```

In [8]:

```
print(train_input)
```

```
[19.6 22. 18.7 17.4 36. 25. 40. 39. 43. 22. 20. 22. 24. 27.5
 43. 40. 24. 21. 27.5 40. 32.8 26.5 36.5 13.7 22.7 15. 37. 35.
 28.7 23.5 39. 21. 23. 22. 44. 22.5 19. 37. 22. 25.6 42. 34.
 5]
```

In [9]:

```
#1차원 배열
print(perch_length.shape)
```

```
(56,)
```

In [10]:

```
#reshape() => shape을 변형
test_array = np.array([1,2,3,4]) #1차원 값으로 배열을 받는 test array 생성됨
print(test_array.shape)

(4,)
```

In [11]:

```
test_array = test_array.reshape(2,2) #x, y, z
print(test_array.shape)

(2, 2)
```

In [12]:

```
test_array
```

Out[12]:

```
array([[1, 2],
       [3, 4]])
```

In [13]:

```
#-1을 사용하면 -1이 표시된 곳은 상관없고 그 다음에 있는 숫자 shape만 맞춰라
train_input = train_input.reshape(-1,1)
test_input = test_input.reshape(-1,1)
```

In [14]:

```
print(train_input.shape, test_input.shape)

(42, 1) (14, 1)
```

In [15]:

```
print(train_input)  #대괄호 하나당 차원 => 2차원
```

```
[[19.6]
 [22. ]
 [18.7]
 [17.4]
 [36. ]
 [25. ]
 [40. ]
 [39. ]
 [43. ]
 [22. ]
 [20. ]
 [22. ]
 [24. ]
 [27.5]
 [43. ]
 [40. ]
 [24. ]
 [21. ]
 [27.5]
 [40. ]
 [32.8]
 [26.5]
 [36.5]
 [13.7]
 [22.7]
 [15. ]
 [37. ]
 [35. ]
 [28.7]
 [23.5]
 [39. ]
 [21. ]
 [23. ]
 [22. ]
 [44. ]
 [22.5]
 [19. ]
 [37. ]
 [22. ]
 [25.6]
 [42. ]
 [34.5]]
```

In [16]:

```
from sklearn.neighbors import KNeighborsRegressor  #최근접 이웃 회귀
```

In [17]:

```
knr = KNeighborsRegressor()
```

In [18]:

```
knr.fit(train_input, train_target)
```

Out[18]:

```
KNeighborsRegressor(algorithm='auto', leaf_size=30, metric='minkowski',
                    metric_params=None, n_jobs=None, n_neighbors=5, p=
2,
                    weights='uniform')
```

In [23]:

```
# 결정계수 ( $R^2$ )
knr.score(test_input, test_target)
```

Out[23]:

```
0.9928094061010639
```

In [27]:

```
knr.score(train_input, train_target) #5/17추가됨
```

Out[27]:

```
0.9698823289099255
```

In [24]:

```
from sklearn.metrics import mean_absolute_error
```

In [25]:

```
test_prediction = knr.predict(test_input)
mae = mean_absolute_error(test_target, test_prediction)
print(mae) #결과 19는 19kg(?) 정도의 평균오차가 있다는 뜻
```

```
19.157142857142862
```

2022-05-17 수업

7. 과대적합(Over fitting) vs 과소적합(Under fitting)

- Train 성능 좋은데, Test 성능 좋지 않음 => 과대적합 (훈련세트에서만 잘 동작)
- Train보다 Test 성능이 더 좋거나, 둘 다 좋지 않음 => 과소적합
- 훈련(Train) 세트가 전체 데이터를 대표한다고 가정하기 때문에 훈련 세트를 잘 학습하는 것이 중요

과소 적합이 나타나는 이유는 Train, Test 데이터 세트 크기가 매우 작거나, Test 데이터가 Train의 특징을 다 담지 못하는 경우

중요: 일반화 된 모델을 만드는 것이 중요!!

병원 예) 요양병원 환자 데이터 => 한국 주요 질병을 예측하는 모델 => 고령화 환자에게만 잘 맞는 모델이 생성됨(일반화 X)

Best 모델: Train 데이터를 사용한 평가 결과가 조금 더 높게
이유는 Train으로 하급했기 때문에 Train 데이터에서 조금 더 높은 성능 보여

시험

현재 우리 모델은 과소적합

- 과소적합을 해결하기 위해서는 모델을 조금 더 복잡하게 만들면(훈련 데이터에 맞게)
- K-NN은 K의 크기를 줄이면 모델이 더 복잡해짐
 - K를 줄이면 국지적인 패턴에 민감해짐
 - K를 늘이면 데이터 전반에 있는 일반적인 패턴을 따름

In [28]:

```
knr.n_neibors = 3
knr.fit(train_input, train_target)
print(knr.score(train_input, train_target))
```

0.9698823289099255

In [31]:

```
print(knr.score(test_input, test_target))
```

0.9928094061010639